

Aprimorando a Recomendação de Itens em Cold-Start através de Framework Adversarial Generativo com Incorporação de Distância Cossenoidal

1st Matheus Carvalho Cardoso
Engenharia de Sistemas e Computação, COPPE
Universidade Federal do Rio de Janeiro, UFRJ
Rio de Janeiro, Brasil
mcc@cos.ufrj.br

2nd Fabrício Magalhães Coutinho
Engenharia de Sistemas e Computação, COPPE
Universidade Federal do Rio de Janeiro, UFRJ
Rio de Janeiro, Brasil
fabmc@cos.ufrj.br

Abstract—Este artigo explora estratégias avançadas para abordar o desafio do "cold start" em sistemas de recomendação. Discutimos a implementação de algoritmos de aprendizado de máquina adaptativos e técnicas de personalização contínua para melhorar a precisão das recomendações em cenários de dados limitados. Através de extensas avaliações experimentais, demonstramos a eficácia de nosso framework proposto.

Index Terms—Cold Start, Sistemas de Recomendação, Adversarial Learning,

I. INTRODUÇÃO

O avanço tecnológico e a digitalização crescente de serviços levaram a uma explosão de dados disponíveis, tornando os sistemas de recomendação [6] [9] um componente essencial em diversas plataformas online. Esses sistemas são vitais para ajudar os usuários a navegarem por uma vasta quantidade de informações, especialmente em contextos como e-commerce e entretenimento digital. Entretanto, o problema do "cold start" - a dificuldade de fazer recomendações precisas para novos usuários ou itens sem dados históricos suficientes - continua sendo um desafio significativo.

Ao abordar esse desafio, não apenas avançamos no estado-da-arte em sistemas de recomendação, mas também abrimos novas perspectivas para a aplicação prática dessas soluções em ambientes do mundo real. O impacto potencial dessas estratégias vai além da otimização de algoritmos, estendendo-se à melhoria substancial da experiência do usuário e à promoção da descoberta eficaz de conteúdo em cenários de "cold start".

A. Contexto e Motivação

Em sistemas de recomendação, o problema de cold start é comum, pois muitos sistemas baseiam suas recomendações nas interações entre usuário e item. Quando um novo usuário ou item entra no sistema, esses métodos enfrentam dificuldades para gerar recomendações eficazes. Este estudo utiliza o framework GAR para abordar este problema, oferecendo uma solução inovadora para o cold start em sistemas de recomendação.

B. Contribuições do Artigo

Este trabalho apresenta as seguintes contribuições principais:

- Implementação e modificação de framework GAR para enfrentar o problema do cold start em sistemas de recomendação.
- Implementação de algoritmos de aprendizado de máquina adaptativos para personalizar recomendações.
- Avaliação experimental que demonstra a eficácia da nova estratégia proposta.

C. Organização do Artigo

O restante deste artigo está organizado da seguinte maneira: Seção 2 apresenta uma revisão da literatura relacionada ao "cold start" em sistemas de recomendação. Seção 3 descreve a metodologia proposta com o framework GAR. Seção 4 discute os resultados dos experimentos. Finalmente, a Seção 5 conclui o artigo com uma discussão sobre implicações práticas e direções futuras para pesquisa.

II. TRABALHOS RELACIONADOS

Este trabalho se insere no contexto de pesquisa sobre recomendações em situações de cold-start e o uso de Variational Auto-Encoders (VAEs) em sistemas de recomendação. Abaixo, discutimos brevemente alguns trabalhos relevantes nessas áreas.

A. Cold-start Recommendation

A recomendação em situações de cold-start enfrenta o desafio de gerar representações eficazes para novos itens devido a diferentes distribuições de dados entre itens quentes e frios. Os métodos existentes para cold-start podem ser amplamente divididos em métodos baseados em robustez e métodos baseados em aprimoramento. Métodos baseados em robustez, como DropoutNet [12] e MTPR [2], simulam cenários de recomendação de novos itens ao descartar sinais de Filtragem Colaborativa (CF) durante a fase de treinamento.

Por outro lado, os métodos baseados em aprimoramento usam representações pré-treinadas para fornecer sinais adicionais de CF e melhorar as representações de conteúdo. Heater [15] é um exemplo que alinha representações de preferências pré-treinadas e representações de conteúdo. No entanto, esses métodos tendem a se concentrar insuficientemente no uso de informações de CF e mais na expressão de preferências por meio de características de conteúdo.

B. Applications of VAEs with Adversarial Learning in Recommendation

Variational Auto-Encoders (VAEs), utilizados para modelar interações usuário-item em sistemas de recomendação, têm sido aprimorados com técnicas de aprendizado adversário. Modelos como Mult-VAE [8], RecVAE [10], e BiVAE [11] destacam o uso de VAEs para inferir preferências do usuário. Em particular, o modelo GAR [1] aplica aprendizado adversário, treinando um gerador e um recomendador de forma adversária para criar representações de itens frios similares aos itens quentes. Esse avanço abre caminhos para recomendações mais eficazes e personalizadas em cenários de cold start, onde a escassez de dados históricos representa um grande desafio.

III. METODOLOGIA

A. Generative Adversarial Framework - GAR

Seja U e I os conjuntos de usuários e itens respectivamente, onde I_w representa os itens quentes e I_c representa os itens frios. Sejam $e_u \in E_u$ e $e_i \in E_w$ os embeddings dos usuários e itens aprendidos através das interações de usuários com o itens. O embeddings dos itens frios são gerados a partir de G com o conteúdo c_i do item.

Seja R o recomendador onde calcula a recomendação de um item quente i como $\hat{y}_{ui} = R(e_u, e_i)$ e um item frio como $\hat{y}_{ui} = R(e_u, G(c_i))$

$$\hat{y}_{ui} = \begin{cases} R(e_u, e_i), & i \in I_w \\ R(e_u, G(c_i)), & i \in I_c \end{cases}$$

O objetivo principal do GAR baseia-se no treinamento adversarial [3] [7] do gerador e do recomendador. Os dados de treinamento são extraídos com base nas interações dos usuários com itens, a fim de gerar embeddings para usuários e itens. O gerador tenta enganar o recomendador, induzindo-o a atribuir mais relevância para os embeddings dos itens frios ($G(c_i)$). O recomendador esforça-se identificar o embedding gerado e atribui uma relevância maior para o embedding pré-treinado (e_i). As funções de perdas adversarial são dadas por:

$$L_{G_{adv}} = \sum_{(u,i,j)} -\ln \sigma(R(e_u, G(c_i)) - R(e_u, e_i))$$

$$L_{R_{adv}} = \sum_{(u,i,j)} -\ln \sigma(R(e_u, e_i) - R(e_u, G(c_i)))$$

onde i representa itens com interação, j sem interação e u representa usuários.

Para o modelo final foi acrescentado uma perda similaridade para auxiliar no treinamento do gerador e para o recomendador

foi adicionado uma perda de recomendação personalizada com o objetivo de manter a capacidade da mesma.

$$L_G = \sum_{(u,i,j)} -(1 - \alpha) \ln \sigma(\hat{y}_{ui}^G - \hat{y}_{ui}) + \alpha \|e_i - e_i^G\|,$$

$$L_R = \sum_{(u,i,j)} -(1 - \beta) \ln \sigma(\hat{y}_{ui} - \hat{y}_{ui}^G) - \beta \ln \sigma(\hat{y}_{ui} - \hat{y}_{uj}). \quad (1)$$

sendo α e β hiperparâmetros utilizados para controlar a relação entre as equações. O melhor resultado do GAR utilizava um $\alpha = 0$, eliminando essa perda de similaridade da modelagem. Como os embeddings gerados por itens novos tem distribuição diferente dos gerados pelo histórico de interações decidimos utilizar a similaridade por cosseno, dada por:

$$1 - \cos(e_i, e_i^G) \quad (2)$$

B. GNN

As redes neurais com grafos tem se destacado em sistemas de recomendações em aprender embedding para usuários e itens [5], [13], porém conforme citado em [1] elas também são sensíveis a problema de cold start.

A Graph Neural Network (GNN) enfrenta desafios significativos no problema de cold-start, principalmente devido à dificuldade em aprender incorporações de alta qualidade para usuários ou itens com interações limitadas. Essa limitação é exacerbada pela convolução do grafo, onde as incorporações imprecisas de vizinhos de cold-start e de outros vizinhos são tratadas igualmente, comprometendo a representação adequada do usuário ou item de cold-start. Adicionalmente, as estratégias de amostragem de vizinhos em GNNs, como a amostragem aleatória ou por importância, muitas vezes não consideram as características de cold-start, limitando a eficácia na obtenção de vizinhos relevantes de alta ordem para esses usuários ou itens [4]

Já no cenário de Warm-Start, GNN destaca-se pela sua notável capacidade de generalização em tarefas downstream. Esse modelo é especialmente eficaz em capturar as nuances estruturais e semânticas dos grafos, facilitando sua aplicação em diversas tarefas downstream com apenas um ajuste fino mínimo. Essa flexibilidade significa que o modelo pode ser adaptado a diferentes conjuntos de dados e contextos de recomendação, eliminando a necessidade de um treinamento extensivo a partir do zero para cada novo cenário. Além disso, a integração de um meta-agregador e uma estratégia de amostragem adaptativa enriquece o processo de agregação durante a convolução do grafo, melhorando significativamente a qualidade das incorporações para usuários e itens com interações abundantes. O modelo de GNN utilizado pelo GAR é o LightGCN [5]

$$R(e_u^{(0)}, \dots, e_u^{(L)}, e_i^{(0)}, \dots, e_i^{(L)}) = \left(\sum_{l=0}^L w_u^{(l)} e_u^{(l)} \right)^T \left(\sum_{l=0}^L w_i^{(l)} e_i^{(l)} \right) \quad (3)$$

onde L representa a profundidade total de convolução do grafo, $(e^{(l)})$ l -ésimo embedding de grafo após l iterações de convolução de grafo e w são os pesos.

O modelo do GAR utilizando LightGCN fica da forma:

$$\hat{y}_{ui} = \begin{cases} R(e_u^{(0)}, \dots, e_u^{(L)}, e_i^{(0)}, \dots, e_i^{(L)}), & i \in I_w \\ R(e_u^{(0)}, \dots, e_u^{(L)}, G^{(0)}(c_i), \dots, G^{(L)}(c_i)), & i \in I_c \end{cases} \quad (4)$$

C. NDCG

O NDCG (Ganho Cumulativo Descontado Normalizado) é uma medida de qualidade de classificação que tem a vantagem de permitir relevância hierárquica para cada item listado. Ao contrário da maioria das métricas de classificação tradicionais que consideram apenas a relevância binária, o NDCG reconhece a possibilidade de diferentes níveis de relevância dos itens. [14]. A fórmula é definida como:

$$NDCG = \frac{DCG}{IDCG} \quad (5)$$

onde o $DCG = \sum_{i=1}^k \frac{rel_i}{\log_2(i+1)}$, $rel_i \in 0,1$ e o $IDCG$ é calculado com a mesma fórmula, porém com ordenada por relevância. Em resumo, o NDCG compara o ganho cumulativo descontado da lista com o ganho cumulativo descontado ideal, normalizando o resultado para estar entre 0 e 1. Quanto mais próximo de 1, melhor é a qualidade da lista classificada.

IV. EXPERIMENTAÇÃO

A. Dataset

O CiteULike é uma base de dados que registra as preferências dos usuários em relação a artigos científicos, onde cada artigo no conjunto de dados contém um resumo, considerado como o conteúdo do item em experimentos futuros. Na distribuição dos conjuntos de dados, realizamos uma divisão aleatória dos itens em duas categorias: 80% são considerados itens quentes e 20% como itens frios.

B. Resultados

A análise empírica foi conduzida para avaliar o impacto das configurações variáveis α e β na performance do modelo proposto. Inicialmente, consideramos $\alpha = 0,0$ e $\beta = 0,7$, introduzidas pelo artigo original como ponto ideal. Porém, iríamos provocar a anulação de α , contornamos essa limitação e explorar α entre os valores de 0,1 a 1,0 em etapas sucessivas, permitindo uma avaliação mais robusta da sua influência.

A Tabela I ilustra os resultados obtidos ao longo de cinco rodadas de testes. Cada rodada foi meticulosamente projetada para capturar a variação no desempenho com ajustes incrementais em α , mantendo β constante.

Nos resultados apresentados, observa-se uma tendência notável na melhoria quando implementado valor de α igual a 0.6. Valores posteriores houve declínio da performance do modelo com o aumento progressivo de α .

Este fenômeno é particularmente evidente ao examinarmos as categorias 'Cold', 'Warm', e 'Hybrid', nas quais as mudanças nos valores de α demonstraram um impacto significativo. A coluna 'Melhor Rodada' destaca as configurações ótimas de α para cada categoria, servindo como benchmark entre o modelo proposto e o modelo do artigo original.

V. CONCLUSÃO

A avaliação apresentada na Tabela II revela que o modelo GAR-Cos supera significativamente as abordagens convencionais, especialmente em cenários de Warm Start, onde alcança um aumento de mais de 29% em NDCG. Tal avanço sugere uma superioridade na gestão da Similarity Loss, onde a distância cosseno, ao invés da distância euclidiana, refletindo uma estratégia mais alinhada à diversidade e complexidade dos padrões de interação do usuário, uma vez que vetores latentes gerados e reais podem ter magnitudes diferentes, influenciando assim o cálculo. Esta abordagem tem implicações promissoras para a personalização e acurácia em sistemas de recomendação, indicando uma direção valiosa para futuras investigações e aplicações práticas.

Porém, se comparado ao modelo de GAR-GNN supracitado, temos um decréscimo de performance em todos cenários. O único que teve **NDCG** superior foi no cenário de Cold Start.

REFERENCES

- [1] Hao Chen, Zefan Wang, Feiran Huang, Xiao Huang, Yue Xu, Yishi Lin, Peng He, and Zhoujun Li. Generative adversarial framework for cold-start item recommendation. In *Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval*, 2022.
- [2] Xiaoyu Du, Xiang Wang, Xiangnan He, Zechao Li, Jinhui Tang, and Tat-Seng Chua. How to learn item representation for cold-start multimedia recommendation? In *Proceedings of the 2020 ACM Multimedia Conference*, 2020.
- [3] Ian J. Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative adversarial networks, 2014.
- [4] Bowen Hao, Jing Zhang, Hongzhi Yin, Cuiping Li, and Hong Chen. Pre-training graph neural networks for cold-start users and items representation, 2020.
- [5] Xiangnan He, Kuan Deng, Xiang Wang, Yan Li, Yongdong Zhang, and Meng Wang. Lightgcn: Simplifying and powering graph convolution network for recommendation, 2020.
- [6] Xiangnan He, Lizi Liao, Hanwang Zhang, Liqiang Nie, Xia Hu, and Tat-Seng Chua. Neural collaborative filtering. In *Proceedings of the 26th International Conference on World Wide Web, WWW '17*, page 173–182, Republic and Canton of Geneva, CHE, 2017. International World Wide Web Conferences Steering Committee.
- [7] Alexia Jolicoeur-Martineau. The relativistic discriminator: a key element missing from standard gan, 2018.
- [8] Dawen Liang, Rahul G. Krishnan, Matthew D. Hoffman, and Tony Jebara. Variational autoencoders for collaborative filtering. 2018.
- [9] G. Linden, B. Smith, and J. York. Amazon.com recommendations: item-to-item collaborative filtering. *IEEE Internet Computing*, 7(1):76–80, 2003.
- [10] Ilya Shenbin, Anton Alekseev, Elena Tutubalina, Valentin Malykh, and Sergey I. Nikolenko. Recvae: A new variational autoencoder for top-n recommendations with implicit feedback. In *Proceedings of the 13th International Conference on Web Search and Data Mining, WSDM '20*, page 528–536, New York, NY, USA, 2020. Association for Computing Machinery.
- [11] Quoc-Tuan Truong, Aghiles Salah, and Hady W. Lauw. Bilateral variational autoencoder for collaborative filtering. 2021.
- [12] Maksims Volkovs, Guangwei Yu, and Tomi Poutanen. Dropoutnet: Addressing cold start in recommender systems. In *Proceedings of the 31st International Conference on Neural Information Processing Systems, NIPS'17*, page 4964–4973, Red Hook, NY, USA, 2017. Curran Associates Inc.
- [13] Xiang Wang, Xiangnan He, Meng Wang, Fuli Feng, and Tat-Seng Chua. Neural graph collaborative filtering. In *Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval, SIGIR'19*, page 165–174, New York, NY, USA, 2019. Association for Computing Machinery.

TABLE I
TABELA DE RODADA DOS TESTES REALIZADOS COM AS CONFIGURAÇÕES DE α E β APRESENTADOS

	Rodada 1	Rodada 2	Rodada 3	Rodada 4	Rodada 5	Melhor Rodada
α	0,1000	0,3500	0,5000	0,6000	1,0000	0,0000
β	0,7000	0,7000	0,7000	0,7000	0,7000	0,7000
Cold	0,0458	0,0458	0,0489	0,0499	0,0289	0,0458
	0,2411	0,2423	0,2556	0,2599	0,1473	0,2418
	0,1364	0,1370	0,1483	0,1507	0,0891	0,1366
Warm	0,0330	0,0331	0,0339	0,0339	0,0298	0,0329
	0,1911	0,1916	0,1919	0,1911	0,1702	0,1908
	0,1169	0,1173	0,1176	0,1167	0,1029	0,1168
Hybrid	0,0541	0,0543	0,0585	0,0590	0,0331	0,0542
	0,1369	0,1372	0,1483	0,1489	0,0809	0,1369
	0,1018	0,1022	0,1132	0,1142	0,0671	0,1018

TABLE II
COMPARATIVO DE PERFORMANCE DE SISTEMAS DE RECOMENDAÇÃO PARA DATASET CITEULIKE. MELHORIA OU DECRÉSCIMO FOI CALCULADO COMPARANDO GAR-GNN-Cos COM O MELHOR VALIDADOR (UNDERLINED).

Methods	Overall Recommendation		Cold Recommendation		Warm Recommendation	
	Precision	NDCG	Precision	NDCG	Precision	NDCG
NCF	0.0303	0.0594	0.0015	0.0032	0.0289	0.0935
DeepMusic	0.0337	0.0621	0.0424	0.1076	0.0289	0.0935
MetaEmb	0.0369	0.0664	0.0452	0.1189	0.0289	0.0935
DropoutNet	0.0360	0.0603	0.0464	0.1199	0.0248	0.0757
Heater	0.0340	0.0572	0.0469	0.1212	0.0270	0.0828
GAR-CF	<u>0.0553</u>	<u>0.0955</u>	<u>0.0483</u>	<u>0.1241</u>	<u>0.0294</u>	<u>0.0936</u>
GAR-GNN-Cos	0.0606	0.1174	0.0505	0.1520	0.0346	0.1209
%Improv.	9.58%	22.93%	4.55%	22.48%	17.68%	29.16%
GAR-GNN	0.0688	0.1424	0.0551	0.1491	0.0526	0.2031
GAR-GNN-Cos	0.0606	0.1174	0.0505	0.1520	0.0346	0.1209
%Improv.	-11.91%	-17.55%	-8.34%	1.94%	-34.22%	-40.47%

- [14] Yining Wang, Liwei Wang, Yuanzhi Li, Di He, and Tie-Yan Liu. A theoretical analysis of ndcg type ranking measures. In *Conference on learning theory*, pages 25–54. PMLR, 2013.
- [15] Ziwei Zhu, Shahin Sefati, Parsa Saadatpanah, and James Caverlee. Recommendation for new users and new items via randomized training and mixture-of-experts transformation. In *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*, 2020.