

Densificacao Informacional Orientada a Tarefa: uma Teoria Fundamentada sobre Compressao de Prompts e Contextos em LLMs

Analise qualitativa a partir do corpus em D:\Codex

31 de maio de 2026

Resumo

Este artigo apresenta uma teoria substantiva produzida por meio de procedimentos da Grounded Theory a partir de um corpus de 20 textos sobre compressao de prompts e contextos em grandes modelos de linguagem. A analise seguiu um processo iterativo de leitura inicial, codificacao aberta, comparacao constante, amostragem teorica, codificacao axial, codificacao seletiva e verificacao de saturacao operacional. A categoria central emergente foi denominada *densificacao informacional orientada a tarefa*. Segundo essa teoria, a compressao de prompts nao e apenas uma tecnica de reducao de tokens, mas um processo de transformar contextos extensos em representacoes menores, mais densas e acionaveis pelo LLM, preservando informacao suficiente para uma tarefa sob restricoes de custo, latencia, memoria, janela de contexto, interpretabilidade e risco de perda informacional. A teoria explica a variacao entre metodos hard, soft, hibridos, query-aware, query-agnostic e integrados a RAG, mostrando que sua adequacao depende da tarefa, do acesso ao modelo, da necessidade de portabilidade, da possibilidade de precomputacao e da tolerancia a hallucination ou perda de grounding.

1 Introducao

O corpus analisado trata de um problema recorrente no uso contemporaneo de grandes modelos de linguagem: prompts e contextos tendem a crescer para acomodar exemplos de in-context learning, cadeias de raciocinio, documentos recuperados por RAG, historicos conversacionais e instrucoes detalhadas. Esse crescimento amplia custos computacionais e financeiros, aumenta latencia, pressiona a janela de contexto e, em cenarios longos, pode degradar o desempenho do modelo pela introducao de ruído, redundancia e vieses de posicao.

A compressao de prompts surge, nos textos, como uma resposta pragmatica e conceitual a esse problema. Contudo, a analise mostrou que a preocupacao central dos autores nao e simplesmente encurtar entradas. A questao substantiva e como condensar o contexto sem destruir aquilo que o torna util para a tarefa. A teoria apresentada neste artigo descreve essa dinamica como um processo de densificacao informacional orientada a tarefa.

2 Procedimento Metodologico

A analise seguiu os passos da Grounded Theory. Primeiro, os 20 arquivos textuais localizados em D:\Codex foram inventariados e tratados como corpus empirico. Em seguida, foram lidos abstracts, introducoes, secoes de metodo, resultados, conclusoes e limitacoes. A unidade de analise foi o incidente conceitual: uma afirmacao sobre problema, mecanismo, trade-off, avaliacao ou consequencia da compressao.

Na codificacao aberta, os incidentes foram nomeados de modo proximo ao dado. Na comparacao constante, os codigos foram confrontados entre textos e familias de metodos. A amostragem teorica foi usada para revisitar textos que esclareciam lacunas, como preservacao de informacao, transferibilidade, pretraining, hallucination, granularidade e casos contrastantes de manejo de contexto longo sem compressao. Na codificacao axial, os codigos foram agrupados em categorias relacionais. Na codificacao seletiva, essas categorias foram integradas em torno da categoria central. A saturacao foi avaliada operacionalmente: uma categoria foi considerada suficientemente saturada quando novos textos refinavam suas propriedades sem alterar a estrutura teorica principal.

3 Categorias Axiais

A Tabela 1 sintetiza as principais categorias axiais que sustentam a teoria.

Tabela 1: Categorias axiais da teoria fundamentada.

Categoria	Fenomeno	Consequencia teorica
Pressao por compressao	Prompts crescem por ICL, CoT, RAG, documentos longos e conversas extensas.	A compressao aparece como resposta a custo, latencia, memoria e limite de janela.
Densidade de informacao util	Contextos longos contem redundancia, ruido e informacao-chave esparsa.	O objetivo e aumentar a proporcao de informacao relevante por token, sentenca ou slot.

Categoria	Fenomeno	Consequencia teorica
Regime representacional	O contexto comprimido pode permanecer textual ou tornar-se vetorial.	Hard prompts favorecem interpretabilidade e portabilidade; soft prompts favorecem maior taxa e cache, mas ampliam opacidade e dependencia do modelo.
Alinhamento e aprendizagem	A representacao comprimida precisa ser compreensivel e utilizavel pelo LLM.	Pretraining, fine-tuning, distilacao, LoRA, scoring e heurísticas são formas de alinhar preservacao e uso.
Avaliacao epistémica	Acuracia downstream não revela sozinha o que foi perdido ou preservado.	Grounding, entidades preservadas, hallucination, custo e robustez tornam-se criterios indispensaveis.
Governanca do ratio	Compressao agressiva economiza mais, mas aumenta risco de perda.	A taxa de compressao deve ser calibrada por tarefa, componente do prompt e tolerancia a erro.
Integracao de sistema	Compressao pode ser parte de pipelines RAG, cache, precomputacao e serving.	A escolha do metodo depende tambem de reuso, armazenamento, retriever e dependencia do modelo.

4 Teoria Substantiva

A teoria final pode ser enunciada da seguinte forma:

Compressao de prompts e contextos em LLMs é um processo de densificacao informacional orientada a tarefa, no qual um contexto extenso é transformado em uma representacao menor, textual ou vetorial, capaz de preservar informacao suficiente para que o modelo execute uma tarefa sob restricoes de custo, latencia, memoria, janela de contexto, interpretabilidade e risco epistemico.

Essa teoria desloca o foco de “reduzir tokens” para “governar a utilidade da informacao preservada”. A compressao bem-sucedida não é necessariamente a mais curta, mas aquela que torna a informacao essencial mais acessivel ao LLM dentro de um orcamento

operacional. Em muitos textos, a compressao tambem funciona como remocao de ruido: ao eliminar informacao irrelevante, o prompt comprimido pode melhorar a resposta. Em outros casos, a compressao introduz perda, incompletude ou hallucination, principalmente quando remove detalhes que o modelo passa a inferir ou preencher indevidamente.

5 Modelo Processual

O processo teorico observado pode ser descrito em cinco movimentos:

1. **Pressao por compressao:** o prompt cresce por demandas de tarefa, documentos recuperados, exemplos ou historico conversacional.
2. **Diagnostico de informatividade:** o metodo estima redundancia, relevancia, posicao, perplexidade, contraste, similaridade ou utilidade de partes do contexto.
3. **Transformacao representacional:** o contexto e convertido em tokens preservados, sentencas selecionadas, resumo textual, memory slots, embeddings, gist tokens ou outra representacao compacta.
4. **Alinhamento ao LLM e a tarefa:** a representacao comprimida e ajustada por heurísticas, scoring, distilacao, pretraining, fine-tuning, instruction tuning ou LoRA.
5. **Validacao operacional e epistemica:** o metodo e julgado por desempenho, custo, latencia, preservacao de informacao, grounding, entidades mantidas, robustez e hallucination.

6 Proposicoes Teoricas

Da categoria central derivam-se seis proposicoes.

1. Quanto mais esparsa e sensível a posicao for a informacao-chave, maior o valor de estrategias query-aware, reordenacao e recuperacao guiada por pergunta.
2. Compressao moderada pode melhorar desempenho ao remover ruido; compressao agressiva aumenta o risco de perda informacional e hallucination.
3. Metodos hard ou textuais sao favorecidos quando interpretabilidade, auditoria, portabilidade e uso com APIs black-box sao importantes.
4. Metodos soft ou vetoriais sao favorecidos quando ha acesso ao modelo, possibilidade de alinhamento e necessidade de altas taxas de compressao ou cache.

5. A aprendizagem do compressor deve estar alinhada ao uso final; pretraining geral pode ajudar representações genéricas, mas destilação orientada a tarefa pode ser mais decisiva em cenários específicos como RAG-QA.
6. Avaliar apenas a resposta final subestima perdas de grounding, detalhes, entidades e fidelidade; por isso, a avaliação da compressão deve ser multidimensional.

7 Discussão

A teoria explica por que os textos não convergem para um único método superior. Cada família de compressão resolve um conjunto diferente de tensões. Métodos textuais e extrativos tendem a ser mais auditáveis e transferíveis, mas podem ter limite de taxa e sofrer com falta de fluidez. Métodos abstrativos sintetizam informação, mas podem introduzir conteúdo não fiel. Métodos soft comprimem de forma mais intensa e podem ser precomputados ou cacheados, mas exigem alinhamento ao modelo e dificultam a interpretação humana. Métodos query-aware aumentam a densidade relevante em tarefas longas, mas reduzem a possibilidade de reutilizar a mesma compressão para muitas perguntas. Métodos query-agnostic favorecem precomputação e escala, mas podem preservar informação irrelevante para uma pergunta específica.

A compressão também se diferencia de outras estratégias de long-context management. Técnicas que expandem a janela de contexto ou alteram mecanismos de atenção preservam mais texto original, mas continuam processando sequências longas. A compressão, por outro lado, aceita uma transformação potencialmente arriscada em troca de economia e densidade. Essa diferença delimita o fenômeno analisado.

8 Limitações

Esta é uma teoria substantiva, não uma teoria universal sobre todos os métodos de contexto longo. Ela foi derivada dos 20 textos disponíveis no corpus local e reflete principalmente trabalhos sobre prompt compression, context compression, RAG, soft prompts, hard prompts, token pruning, sentence selection e avaliação de preservação. Novos estudos sobre KV-cache, attention optimization, privacidade, segurança, compressão multimodal ou métodos posteriores podem exigir novas iterações de codificação.

Outra limitação é que a saturação foi operacional e documental: as categorias se estabilizaram no corpus analisado, mas não foram validadas por entrevistas, experimentos reproduzidos ou revisão sistemática externa.

9 Conclusao

A Grounded Theory produzida indica que a compressao de prompts e contextos em LLMs deve ser compreendida como densificacao informacional orientada a tarefa. A questao central nao e apenas quanto o prompt foi reduzido, mas que informacao permaneceu, em que forma representacional, com que grau de fidelidade, a que custo e com que capacidade de ser usada pelo modelo.

Essa teoria oferece uma lente para comparar metodos existentes e projetar novos estudos. Em vez de perguntar apenas qual metodo comprime mais, ela sugere perguntar: que tipo de informacao a tarefa exige, qual regime representacional e adequado, como o compressor se alinha ao LLM, qual taxa de compressao e segura, que riscos epistemicos surgem e quais metricas sao necessarias para demonstrar preservacao real.